MF 与 NCF：BERT 与 Word2Vec 嵌入对比

六组标题特征模型与两个 ID 基线；下表列出各自选定 checkpoint 的最终测试指标。

实验情况	最佳 epoch	实际轮数	Recall@10	HitRatio@10	nDCG@10	nDCG 相对 ID 基线
MF + ID 基线	5	10	0.0890	0.3403	0.0830	参照
MF + BERT 静态	44	49	0.1086	0.3763	0.0976	+17.53%
MF + BERT 上下文	14	19	0.1003	0.3566	0.0914	+10.14%
MF + Word2Vec	25	30	0.0564	0.2532	0.0526	-36.61%
NCF + ID 基线	28	33	0.0998	0.3577	0.0867	参照
NCF + BERT 静态	46	51	0.1023	0.3554	0.0914	+5.34%
NCF + BERT 上下文	31	36	0.1016	0.3554	0.0926	+6.75%
NCF + Word2Vec	8	13	0.0796	0.3194	0.0702	-19.07%

绿色单元格表示同一模型家族内该项测试指标的最高原始值，并列值均高亮；显示值保留四位小数。高亮仅描述测试结果，不用测试集选择训练轮数或嵌入方式。

每一行的三个测试指标都来自同一个 checkpoint。nDCG 相对变化 =（该方法 / 同模型 ID 基线 - 1）× 100%；单 seed 结果不代表统计显著性。

验证指标与训练误差：八组完整对比

checkpoint 以最高验证 nDCG@10 选取，原始值相同则取最早 epoch；训练 MSE 对应同一轮。

实验情况	选定训练 MSE	验证 Recall@10	验证 HitRatio@10	验证 nDCG@10
MF + ID 基线	0.1434	0.0838	0.2660	0.0729
MF + BERT 静态	0.0788	0.1302	0.3806	0.1045
MF + BERT 上下文	0.1001	0.1072	0.3570	0.0877
MF + Word2Vec	0.0882	0.0625	0.2683	0.0528
NCF + ID 基线	0.0816	0.1255	0.3617	0.0949
NCF + BERT 静态	0.0778	0.1348	0.3853	0.1016
NCF + BERT 上下文	0.0916	0.1272	0.3853	0.1004
NCF + Word2Vec	0.1205	0.0726	0.2730	0.0580

绿色为同一模型家族内该项验证排序指标的最高值；不同指标的最高值可能来自不同方法。训练 MSE 越低越好，但选模型的标准始终是验证 nDCG。

本次按验证 nDCG 选择：**MF**：BERT 静态（验证 nDCG 0.1045）；**NCF**：BERT 静态（验证 nDCG 0.1016）。

统一训练、评价口径与三种标题特征

直接使用 Word2Vec 标题向量；该分支不调用 BERT。各方法都与可训练电影 ID 向量相加。

训练配置：混合负样本池 + MSE，维度 64，Adam 学习率 0.001，weight decay 1e-06，batch 1024；最多 100 轮，patience 5，seed 42。
数据划分：按用户时间顺序 8:1:1；训练 79,619、验证 9,596、测试 10,785 条。验证评估 846 位用户，测试评估 861 位用户。

Recall@10：每位用户的相关电影被 Top-10 找回的比例，再对用户取平均。
HitRatio@10：Top-10 至少命中一部相关电影的用户比例。
nDCG@10：命中位置越靠前，折扣后的奖励越大，再归一化。
训练 MSE：二值采样标签上的均方误差，越低越好。

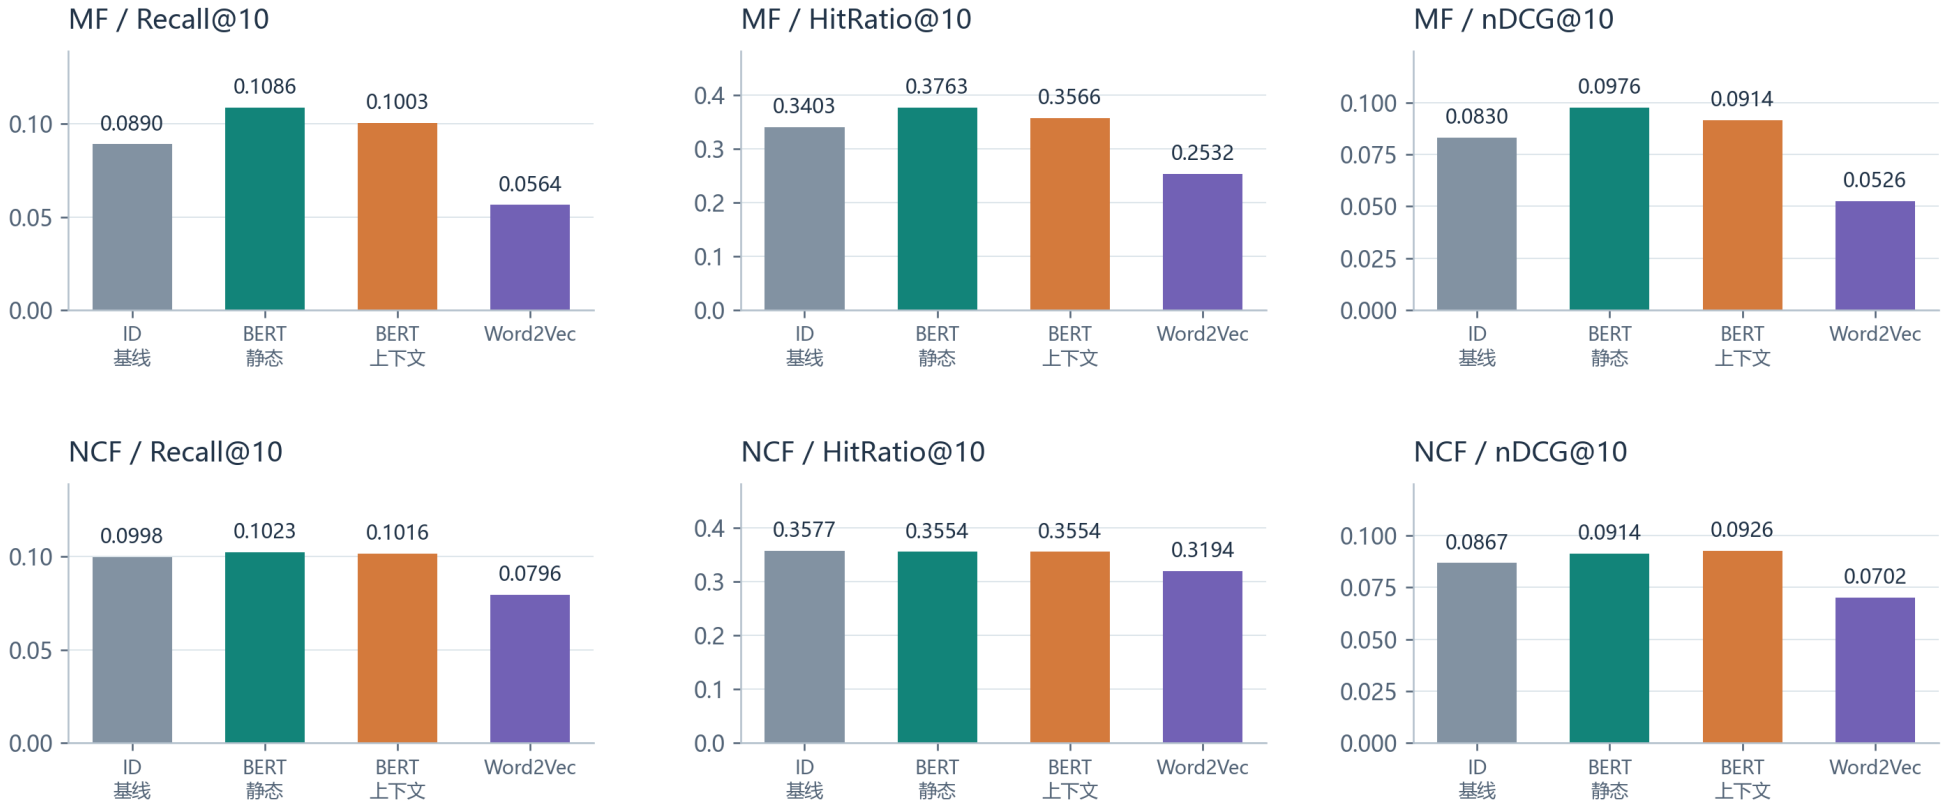
标题特征	冻结特征的生成方式	可训练投影 / 新增参数
BERT 静态	BERT 输入词向量的 WordPiece 均值，不运行编码器	768 → 64，无偏置 +49,152 参数
BERT 上下文	BERT 最后一层标题 token 均值，排除特殊符号和填充	768 → 64，无偏置 +49,152 参数
Word2Vec	标题中词表内 center 词向量取均值；按电影 ID 对齐，不额外归一化	100 → 64，无偏置 +6,400 参数

标签与负采样：4-5 分为正反馈，1-2 分为显式负反馈，3 分不提供训练标签。每个训练正样本配一个负样本，从该用户训练期真实负反馈与训练期未评分、全局已见电影的并集中均匀抽取；每轮重采样。

候选与评估：候选为训练期全局已知电影，并排除用户先前交互；测试先前交互含训练与验证。各模型在选定 checkpoint 上计算一次最终测试结果。

三个测试指标：四种表示方法并列

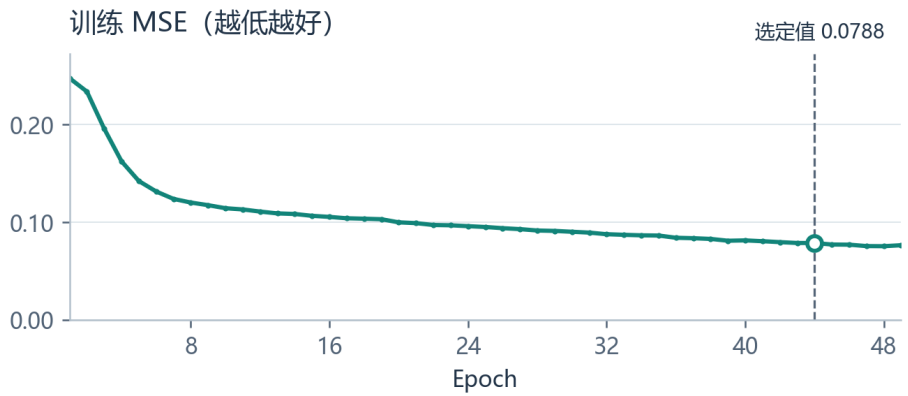
灰色为 ID 基线，绿色为 BERT 静态，橙色为 BERT 上下文，紫色为自训练 Word2Vec。



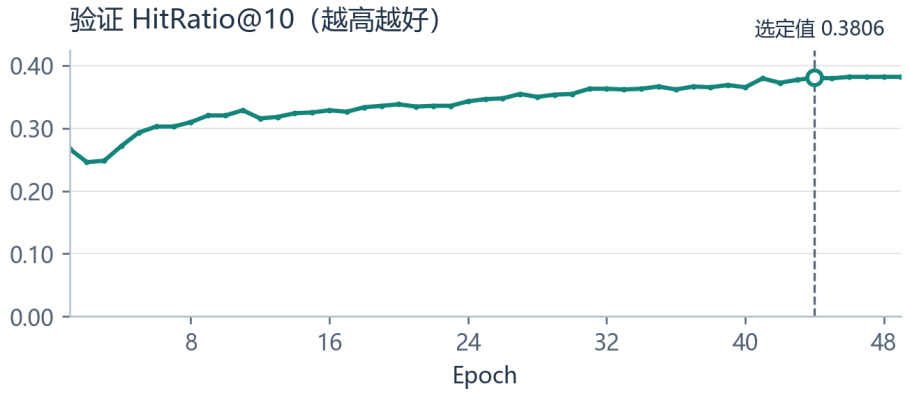
每根柱子代表一次最终测试评估。纵轴从 0 开始，同一指标在 MF 与 NCF 两行采用相同量程；表格中的相对变化与图中的绝对分数不要混淆。

MF + BERT 静态：四项逐轮指标

选定 epoch 44 / 实际训练 49 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









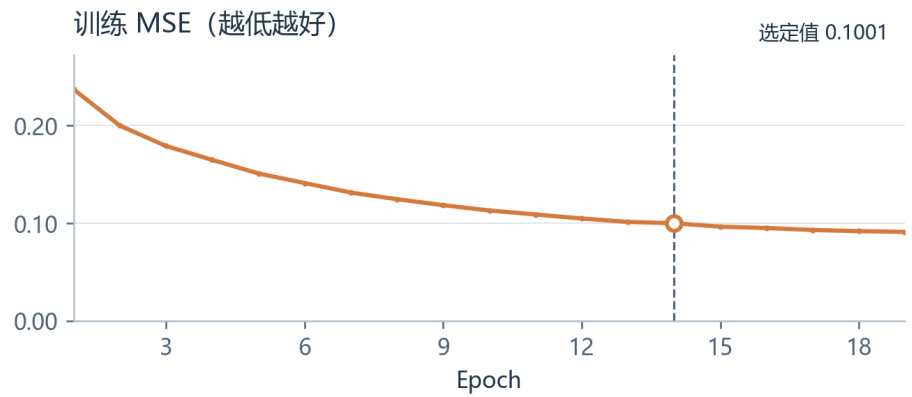
最终测试：Recall@10 = 0.1086 | HitRatio@10 = 0.3763 | nDCG@10 = 0.0976

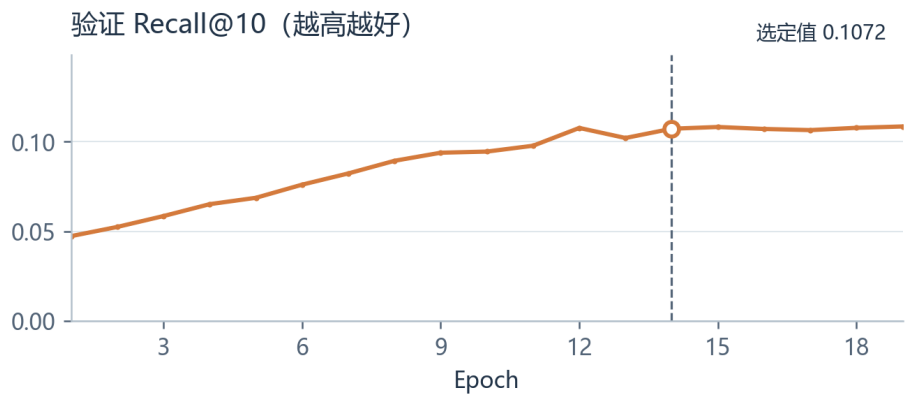
第 44 轮的验证 nDCG 为 0.1045，选定训练 MSE 为 0.0788。记录截至第 49 轮；后续训练损失变化不改变已选 checkpoint。

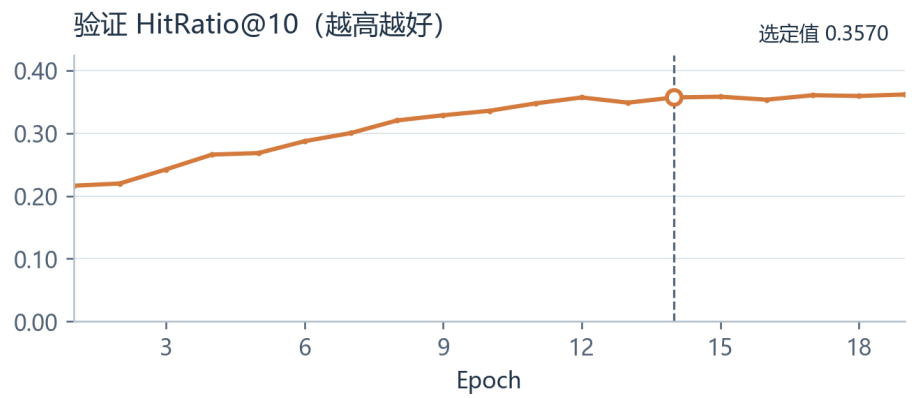
曲线为逐轮原始值，不平滑、不延长结束后的序列。六组实验页面对同一指标使用相同纵轴量程。

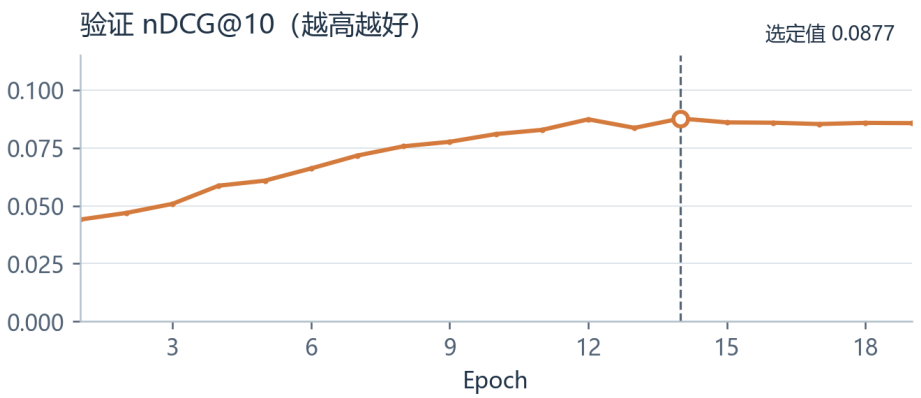
MF + BERT 上下文：四项逐轮指标

选定 epoch 14 / 实际训练 19 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









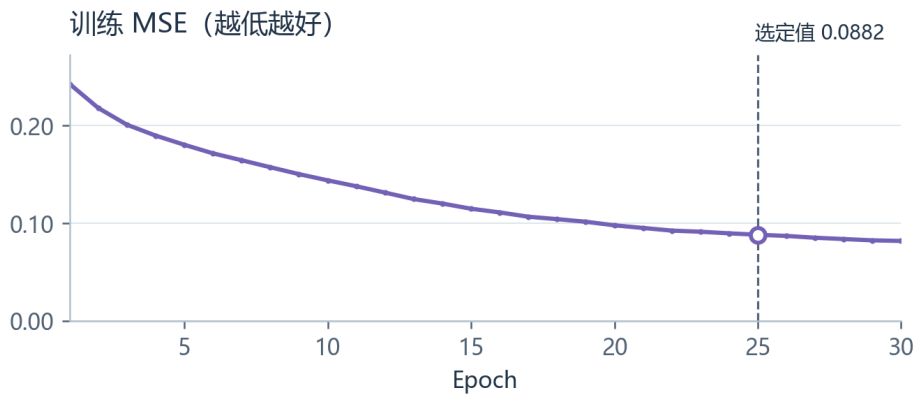
最终测试：Recall@10 = 0.1003 | HitRatio@10 = 0.3566 | nDCG@10 = 0.0914

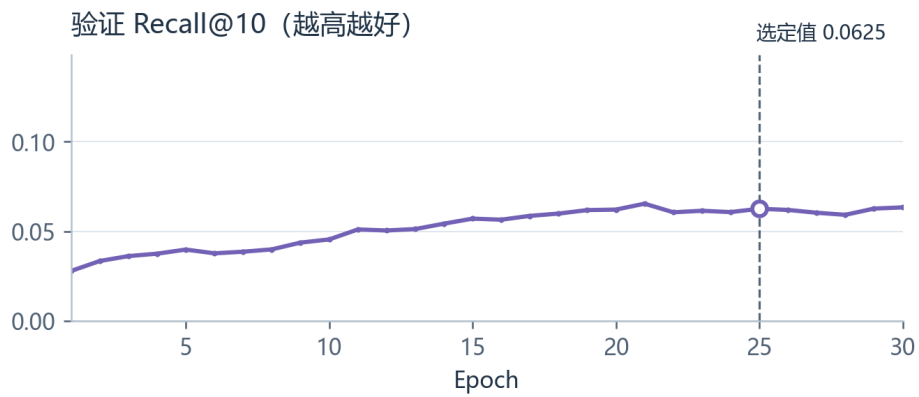
第 14 轮的验证 nDCG 为 0.0877，选定训练 MSE 为 0.1001。记录截至第 19 轮；后续训练损失变化不改变已选 checkpoint。

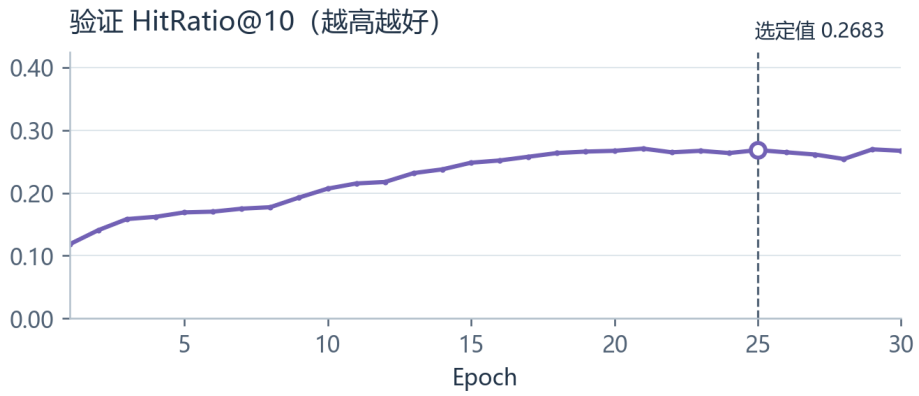
曲线为逐轮原始值，不平滑、不延长结束后的序列。六组实验页面对同一指标使用相同纵轴量程。

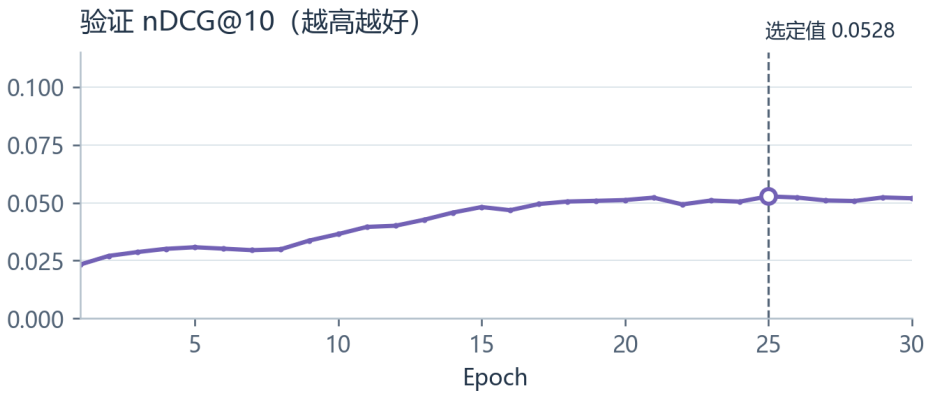
MF + Word2Vec：四项逐轮指标

选定 epoch 25 / 实际训练 30 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









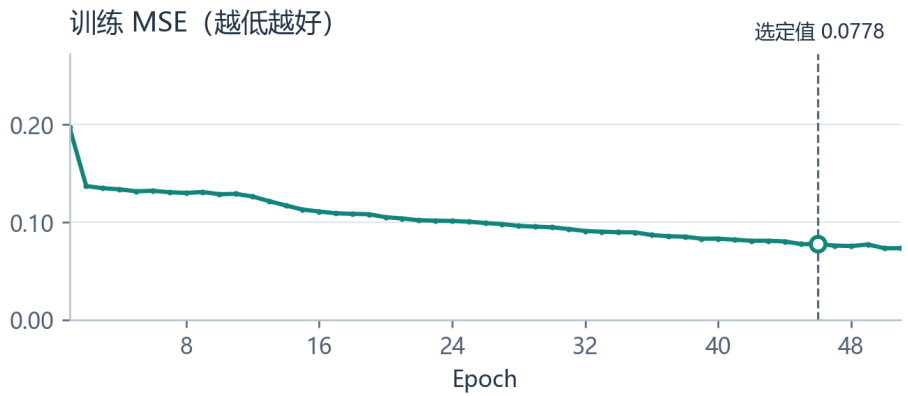
最终测试：Recall@10 = 0.0564 | HitRatio@10 = 0.2532 | nDCG@10 = 0.0526

第 25 轮的验证 nDCG 为 0.0528，选定训练 MSE 为 0.0882。记录截至第 30 轮；后续训练损失变化不改变已选 checkpoint。

曲线为逐轮原始值，不平滑、不延长结束后的序列。六组实验页面对同一指标使用相同纵轴量程。

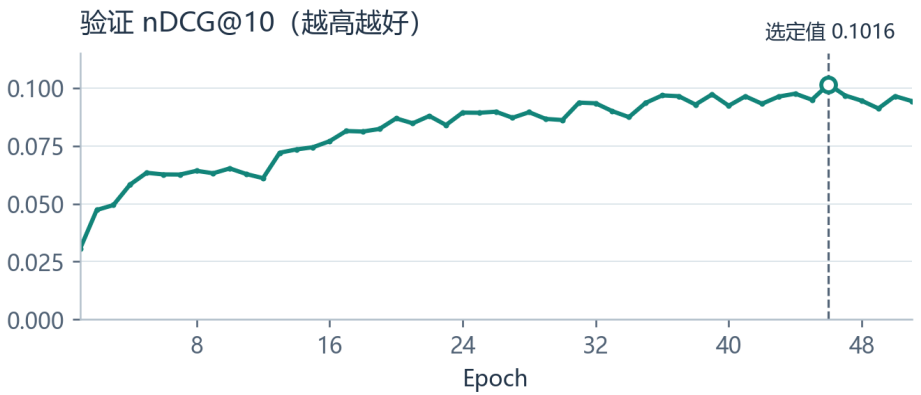
NCF + BERT 静态：四项逐轮指标

选定 epoch 46 / 实际训练 51 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









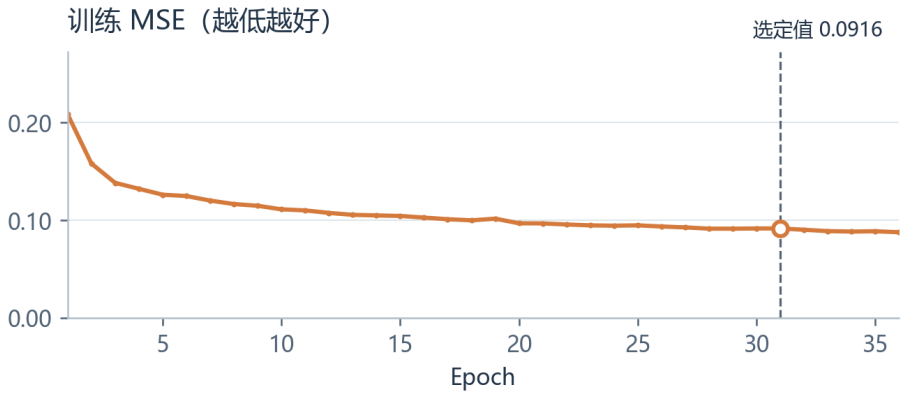
最终测试：Recall@10 = 0.1023 | HitRatio@10 = 0.3554 | nDCG@10 = 0.0914

第 46 轮的验证 nDCG 为 0.1016，选定训练 MSE 为 0.0778。记录截至第 51 轮；后续训练损失变化不改变已选 checkpoint。

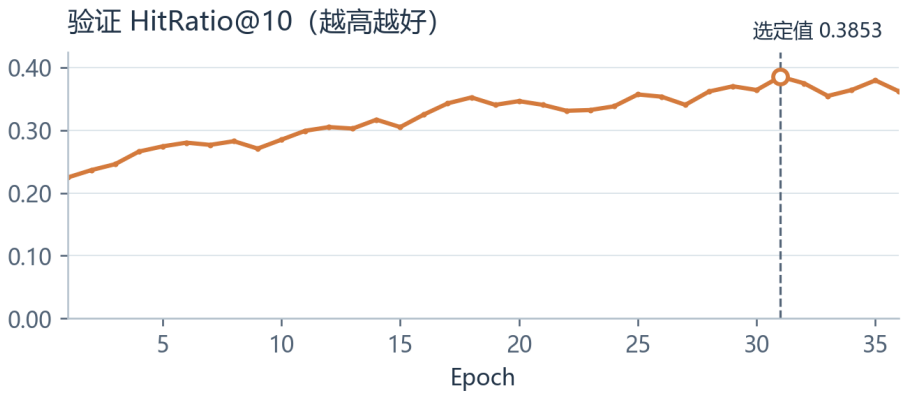
曲线为逐轮原始值，不平滑、不延长结束后的序列。六组实验页面对同一指标使用相同纵轴量程。

NCF + BERT 上下文：四项逐轮指标

选定 epoch 31 / 实际训练 36 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









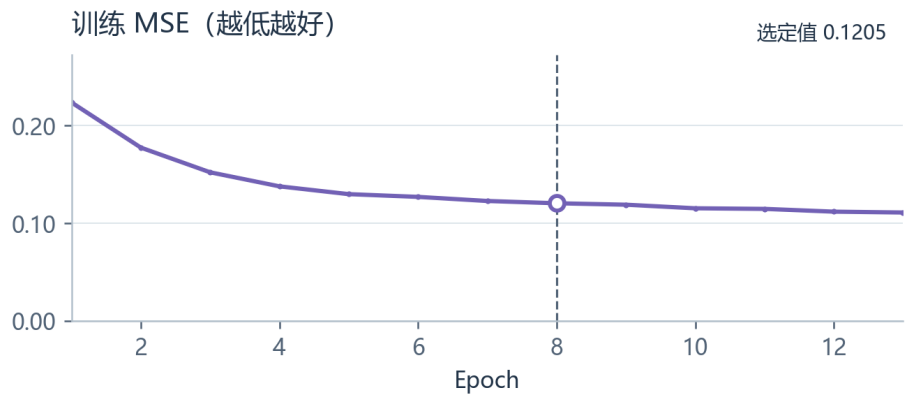
最终测试：Recall@10 = 0.1016 | HitRatio@10 = 0.3554 | nDCG@10 = 0.0926

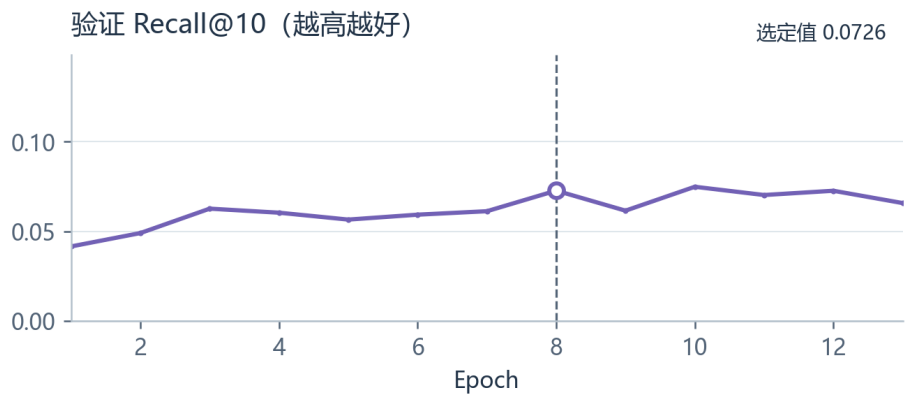
第 31 轮的验证 nDCG 为 0.1004，选定训练 MSE 为 0.0916。记录截至第 36 轮；后续训练损失变化不改变已选 checkpoint。

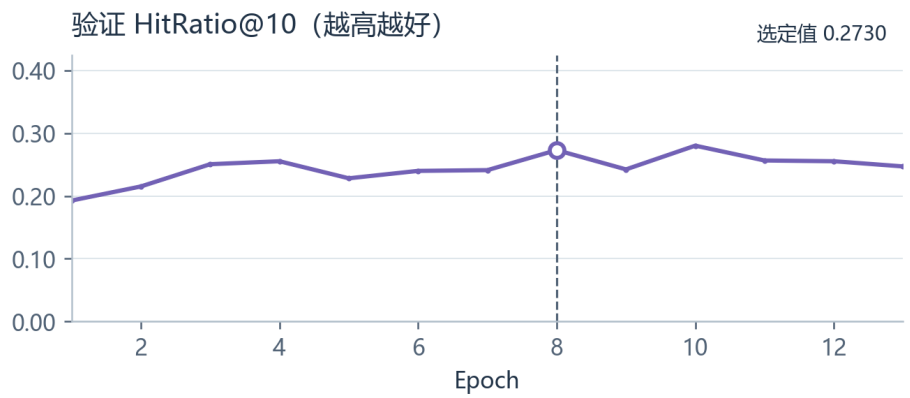
曲线为逐轮原始值，不平滑、不延长结束后的序列。六组实验页面对同一指标使用相同纵轴量程。

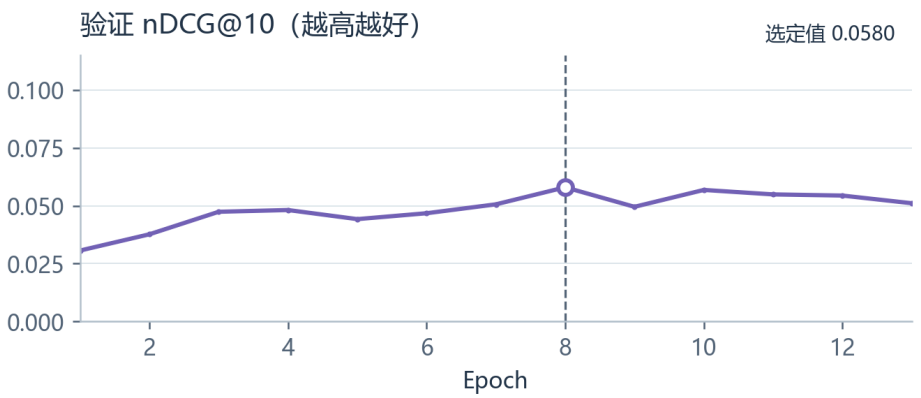
NCF + Word2Vec：四项逐轮指标

选定 epoch 8 / 实际训练 13 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









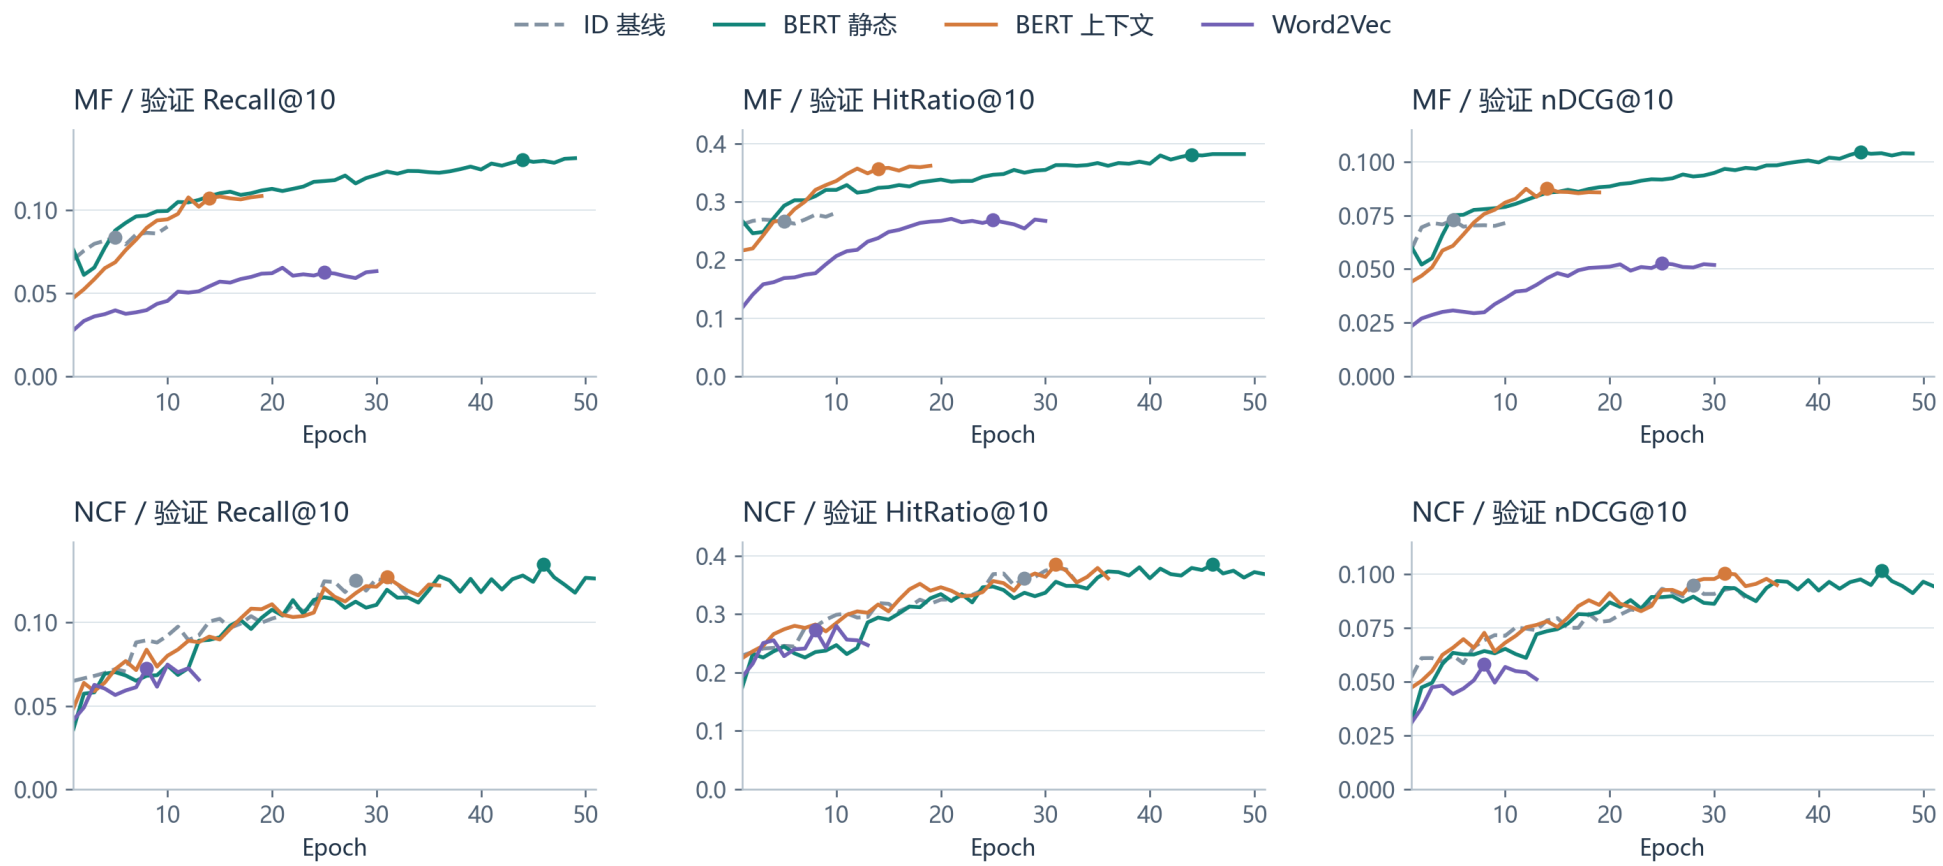
最终测试：Recall@10 = 0.0796 | HitRatio@10 = 0.3194 | nDCG@10 = 0.0702

第 8 轮的验证 nDCG 为 0.0580，选定训练 MSE 为 0.1205。记录截至第 13 轮；后续训练损失变化不改变已选 checkpoint。

曲线为逐轮原始值，不平滑、不延长结束后的序列。六组实验页面对同一指标使用相同纵轴量程。

验证曲线叠加：每个模型的四种表示

完整历史按实际训练轮数截断；圆点为各自选定 checkpoint，横轴统一到第 51 轮。



同一模型家族共享训练口径与评价人群，曲线展示真实波动。曲线长度表示训练轮数；日志未提供所有方法可比的耗时记录，因此不据此比较运行速度。

Word2Vec 的实际变化与方法选择

所有差值由保存的原始指标计算；以下结论仅适用于当前数据、配置和单次随机种子。

MF：按验证 nDCG 选择的方法为 BERT 静态（验证 0.1045，其测试 0.0976）。测试 nDCG 的最高观测值来自 BERT 静态（0.0976），该观察不作为选模型依据。

NCF：按验证 nDCG 选择的方法为 BERT 静态（验证 0.1016，其测试 0.0914）。测试 nDCG 的最高观测值来自 BERT 上下文（0.0926），该观察不作为选模型依据。

Word2Vec 相对同模型 ID 基线

模型	Δ Recall@10 百分点	Δ HitRatio@10 百分点	Δ nDCG@10 百分点	nDCG 相对变化
MF	-3.259	-8.711	-3.039	-36.61%
NCF	-2.016	-3.833	-1.654	-19.07%

MF Word2Vec 测试 nDCG：相对 BERT 静态 -4.495 个百分点；相对 BERT 上下文 -3.881 个百分点。
NCF Word2Vec 测试 nDCG：相对 BERT 静态 -2.117 个百分点；相对 BERT 上下文 -2.239 个百分点。

百分点表示分数之差乘以 100；相对变化表示比值变化。仅凭本次单 seed 的差异，不能断言某种词向量或编码方式普遍更优。

覆盖率、比较限制与可复现来源

报告保留原有 BERT 结果，新增直接 Word2Vec 融合结果；没有生成逐轮测试曲线。

解释结果时需要保留的边界

1. Word2Vec 元数据记录维度 100、词表 14,951；电影覆盖 1,682/1,682（100.00%），标题词命中 5,750/6,695（85.88%）。电影均有向量，不等于每个词均在词表内。外部预训练语料尚未核实；仅能确认本次推荐训练不读取验证/测试标签，不能据此断言整个预训练链路没有泄漏。
2. 所有结果只有一个 seed，未给出置信区间或显著性检验。BERT 各增加 49,152 个投影参数，Word2Vec 增加 6,400 个；输入维度、参数量与预训练来源不同，且各模型的 ID 初始化未逐参数对齐，变化不能单独归因于文本语义。
3. 评价仅覆盖训练期全局已知电影；测试排除了 13 条冷启动正反馈，不衡量冷启动收益。BERT 上下文编码使用项目内 PyTorch 实现，未新增与标准库的数值一致性验证。
4. 记录包含训练 MSE 与验证排序指标，不包含可比的验证损失、逐轮测试指标及全套运行时间；报告仅展示已实际记录的数据。

原始记录与报告材料

ID 基线：outputs/ranking_benchmark_mixed_pool_100/
BERT 静态：outputs/bert_static_word_embedding_mixed_pool_100/
BERT 上下文：outputs/bert_contextual_title_mixed_pool_100/
Word2Vec：outputs/word2vec_title_mixed_pool_100/

各目录内 mf_sampled_mse/metrics.json、ncf_sampled_mse/metrics.json 提供逐轮记录，summary.json 用于交叉核对。
Word2Vec 覆盖率：data/pretrained_word2vec/coverage.json；模型输入采用该目录提供的电影标题向量。
数据快照：results/bert_comparison_report_data.json，含六组与基线原始历史、配置、覆盖率、来源及图表 SHA-256。
生成脚本：build_bert_report.py（charts / pdf / verify）；图表：output/pdf/figures/（PNG 与 SVG）。