MF：五种表示的最终测试对比

综合报告包含八组标题特征模型与两个 ID 基线；Word2Vec L2 为新增归一化对照。

实验情况	最佳 epoch	实际轮数	Recall@10	HitRatio@10	nDCG@10	nDCG 相对 ID 基线
MF + ID 基线	5	10	0.0890	0.3403	0.0830	参照
MF + BERT 静态	44	49	0.1086	0.3763	0.0976	+17.53%
MF + BERT 上下文	14	19	0.1003	0.3566	0.0914	+10.14%
MF + Word2Vec	25	30	0.0564	0.2532	0.0526	-36.61%
MF + Word2Vec L2	65	70	0.1047	0.3693	0.0917	+10.42%

绿色单元格表示该项测试指标的最高原始值，并列值均高亮。每行三个测试指标来自同一验证选定 checkpoint；高亮仅描述测试结果，不作为模型选择依据。

nDCG 相对变化 =（该方法 / 同模型 ID 基线 - 1）× 100%；表格保留四位小数，相对变化使用未舍入数值。

新增 L2 对照：测试 nDCG 相对原始 Word2Vec +74.20%，相对 ID 基线 +10.42%。原始版本保留，便于区分归一化收益与相对基线的收益。

NCF：五种表示的最终测试对比

综合报告包含八组标题特征模型与两个 ID 基线；Word2Vec L2 为新增归一化对照。

实验情况	最佳 epoch	实际轮数	Recall@10	HitRatio@10	nDCG@10	nDCG 相对 ID 基线
NCF + ID 基线	28	33	0.0998	0.3577	0.0867	参照
NCF + BERT 静态	46	51	0.1023	0.3554	0.0914	+5.34%
NCF + BERT 上下文	31	36	0.1016	0.3554	0.0926	+6.75%
NCF + Word2Vec	8	13	0.0796	0.3194	0.0702	-19.07%
NCF + Word2Vec L2	11	16	0.0978	0.3531	0.0842	-2.87%

绿色单元格表示该项测试指标的最高原始值，并列值均高亮。每行三个测试指标来自同一验证选定 checkpoint；高亮仅描述测试结果，不作为模型选择依据。

nDCG 相对变化 =（该方法 / 同模型 ID 基线 - 1）× 100%；表格保留四位小数，相对变化使用未舍入数值。

新增 L2 对照：测试 nDCG 相对原始 Word2Vec +20.02%，相对 ID 基线 -2.87%。原始版本保留，便于区分归一化收益与相对基线的收益。

MF：验证指标与选定训练误差

checkpoint 以最高验证 nDCG@10 选取，原始值相同则取最早 epoch；训练 MSE 对应同一轮。

实验情况	选定训练 MSE	验证 Recall@10	验证 HitRatio@10	验证 nDCG@10
MF + ID 基线	0.1434	0.0838	0.2660	0.0729
MF + BERT 静态	0.0788	0.1302	0.3806	0.1045
MF + BERT 上下文	0.1001	0.1072	0.3570	0.0877
MF + Word2Vec	0.0882	0.0625	0.2683	0.0528
MF + Word2Vec L2	0.0630	0.1307	0.3972	0.0992

绿色为各项验证排序指标的最高值；不同指标的最高值可能来自不同方法。训练 MSE 越低越好，选模型的标准始终是验证 nDCG。

按验证 nDCG 选择：**BERT 静态**（0.1045）。

L2 纳入依据：验证 nDCG 从原始 Word2Vec 的 0.0528 提升到 0.0992，满足训练前说明的报告纳入标准。

NCF：验证指标与选定训练误差

checkpoint 以最高验证 nDCG@10 选取，原始值相同则取最早 epoch；训练 MSE 对应同一轮。

实验情况	选定训练 MSE	验证 Recall@10	验证 HitRatio@10	验证 nDCG@10
NCF + ID 基线	0.0816	0.1255	0.3617	0.0949
NCF + BERT 静态	0.0778	0.1348	0.3853	0.1016
NCF + BERT 上下文	0.0916	0.1272	0.3853	0.1004
NCF + Word2Vec	0.1205	0.0726	0.2730	0.0580
NCF + Word2Vec L2	0.1039	0.1037	0.3357	0.0823

绿色为各项验证排序指标的最高值；不同指标的最高值可能来自不同方法。训练 MSE 越低越好，选模型的标准始终是验证 nDCG。

按验证 nDCG 选择：**BERT 静态**（0.1016）。

L2 纳入依据：验证 nDCG 从原始 Word2Vec 的 0.0580 提升到 0.0823，满足训练前说明的报告纳入标准。

统一训练口径与四种标题特征

Word2Vec 原始版与 L2 版均不调用 BERT；冻结标题特征经可训练投影后与电影 ID 向量相加。

训练配置：混合负样本池 + MSE，维度 64，Adam 学习率 0.001，weight decay 1e-06，batch 1024；最多 100 轮，patience 5，seed 42。
数据划分：按用户时间顺序 8:1:1；训练 79,619、验证 9,596、测试 10,785 条。验证评估 846 位用户，测试评估 861 位用户。

Recall@10：每位用户的相关电影被 Top-10 找回的比例，再对用户取平均。
HitRatio@10：Top-10 至少命中一部相关电影的用户比例。
nDCG@10：命中位置越靠前，折扣后的奖励越大，再归一化。
训练 MSE：二值采样标签上的均方误差，越低越好。

标题特征	冻结特征的生成方式	可训练投影 / 新增参数
BERT 静态	BERT 输入词向量的 WordPiece 均值，不运行编码器	768 → 64，无偏置 +49,152 参数
BERT 上下文	BERT 最后一层标题 token 均值，排除特殊符号和填充	768 → 64，无偏置 +49,152 参数
Word2Vec	标题中词表内 center 词向量取均值；按电影 ID 对齐，不额外归一化	100 → 64，无偏置 +6,400 参数
Word2Vec L2	对上述 100 维电影均值向量逐行 L2 归一化，再做可训练线性投影	100 → 64，无偏置 +6,400 参数

标签与负采样：4-5 分为正反馈，1-2 分为显式负反馈，3 分不提供训练标签。每轮为每个训练正样本配一个负样本，从该用户训练期显式负反馈与训练期未评分、全局已见电影的并集中均匀抽取。

候选与评估：候选为训练期全局已知电影，并排除用户先前交互；测试先前交互含训练与验证。各模型在选定 checkpoint 上计算一次最终测试结果。

三个测试指标：五种表示方法并列

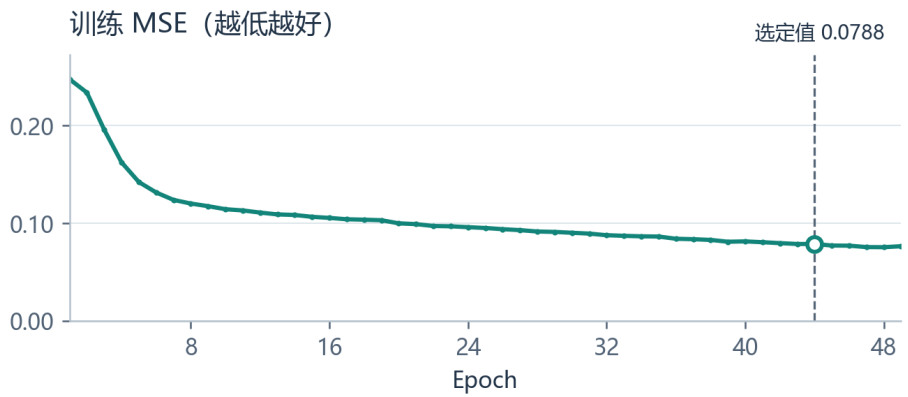
灰：ID 基线；绿：BERT 静态；橙：BERT 上下文；紫：原始 Word2Vec；蓝：Word2Vec L2。



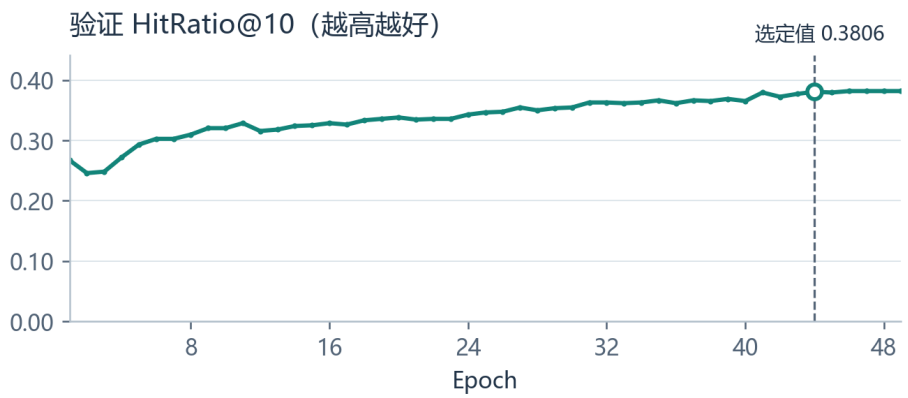
每根柱子代表一次最终测试评估。纵轴从 0 开始，同一指标在 MF 与 NCF 两行采用相同量程；表格中的相对变化与图中的绝对分数不要混淆。

MF + BERT 静态：四项逐轮指标

选定 epoch 44 / 实际训练 49 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









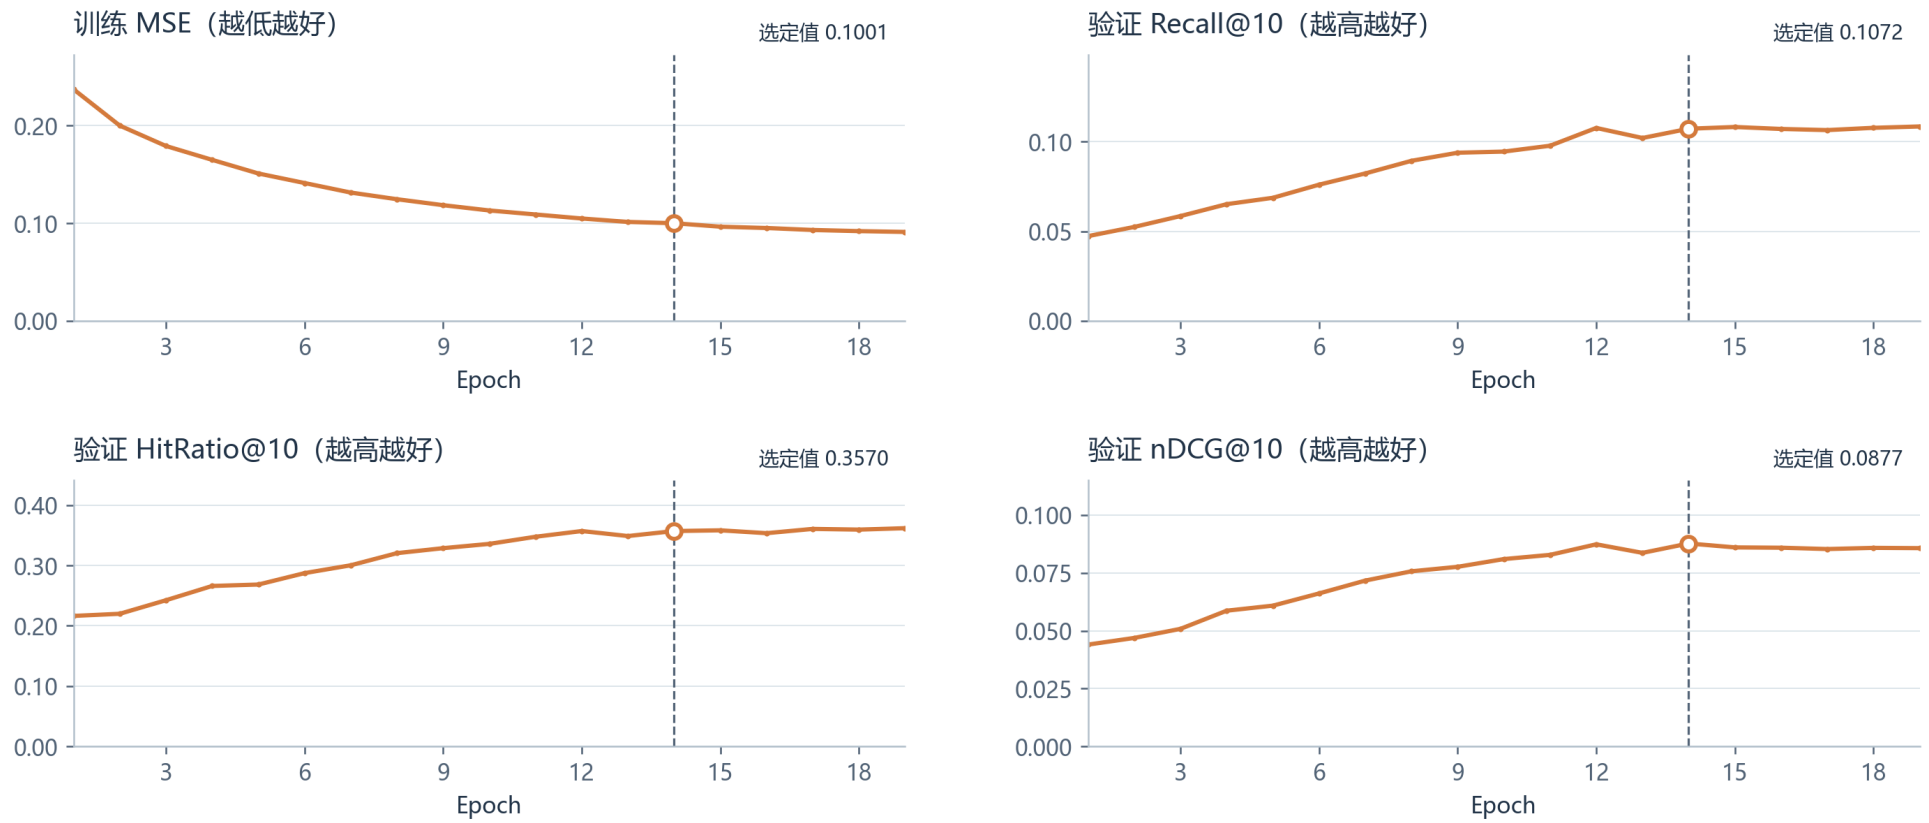
最终测试：Recall@10 = 0.1086 | HitRatio@10 = 0.3763 | nDCG@10 = 0.0976

第 44 轮的验证 nDCG 为 0.1045，选定训练 MSE 为 0.0788。记录截至第 49 轮；后续训练损失变化不改变已选 checkpoint。

曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

MF + BERT 上下文：四项逐轮指标

选定 epoch 14 / 实际训练 19 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。



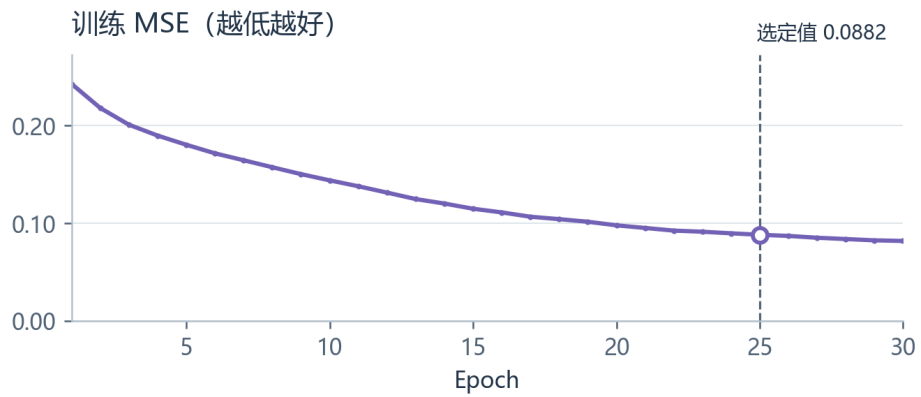
最终测试：Recall@10 = 0.1003 | HitRatio@10 = 0.3566 | nDCG@10 = 0.0914

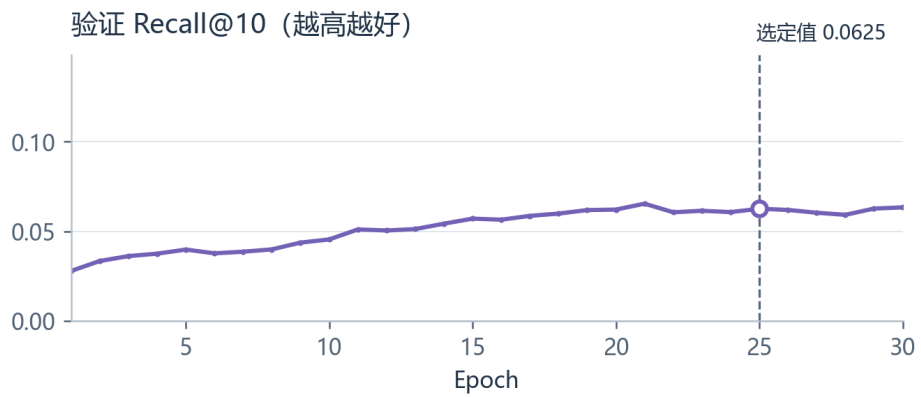
第 14 轮的验证 nDCG 为 0.0877，选定训练 MSE 为 0.1001。记录截至第 19 轮；后续训练损失变化不改变已选 checkpoint。

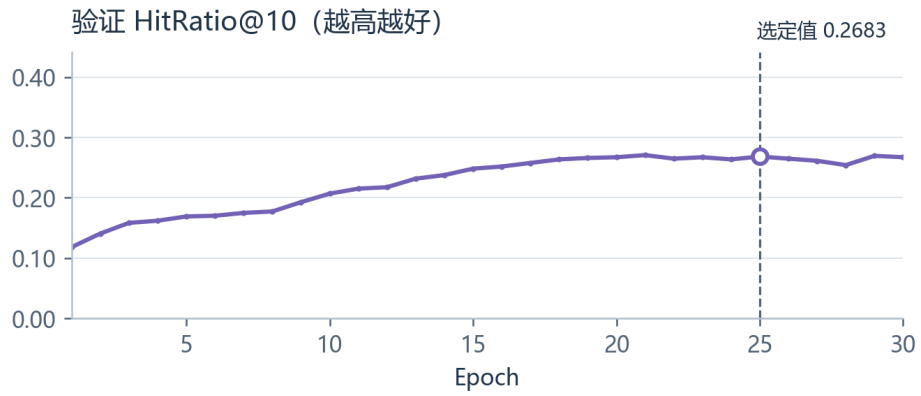
曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

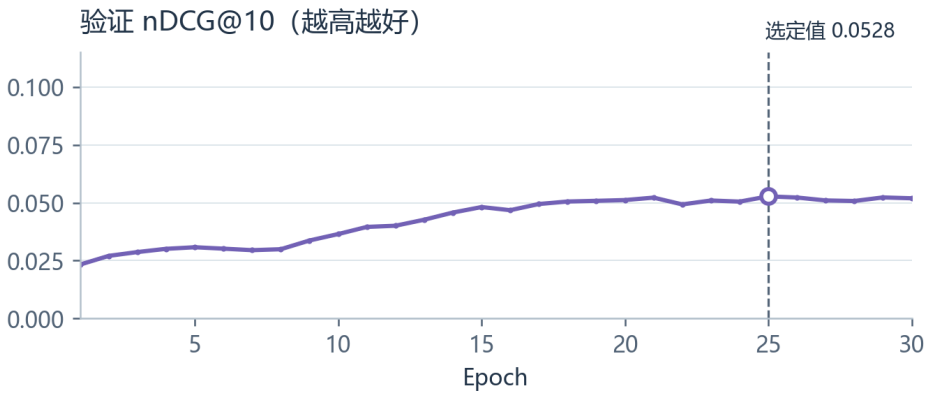
MF + Word2Vec：四项逐轮指标

选定 epoch 25 / 实际训练 30 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









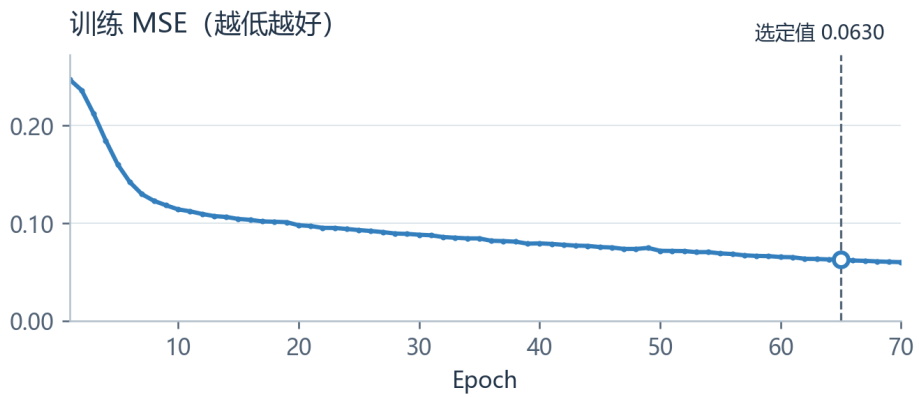
最终测试：Recall@10 = 0.0564 | HitRatio@10 = 0.2532 | nDCG@10 = 0.0526

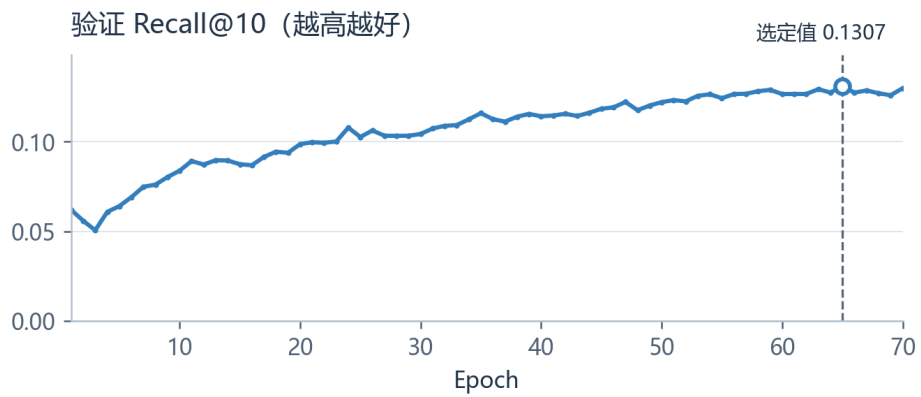
第 25 轮的验证 nDCG 为 0.0528，选定训练 MSE 为 0.0882。记录截至第 30 轮；后续训练损失变化不改变已选 checkpoint。

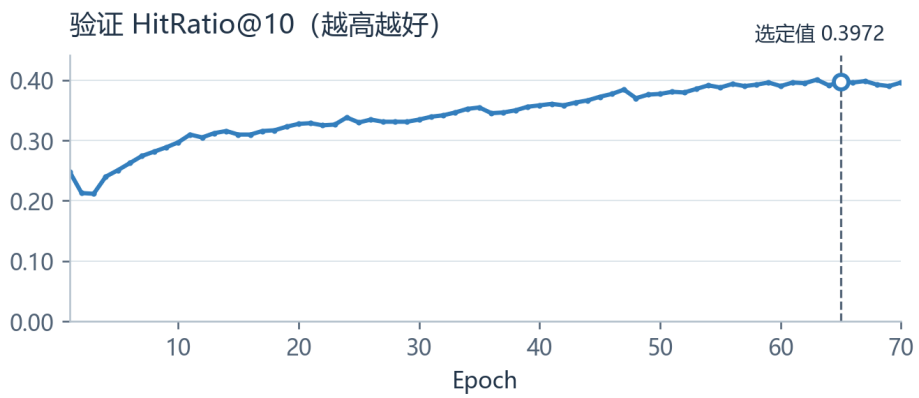
曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

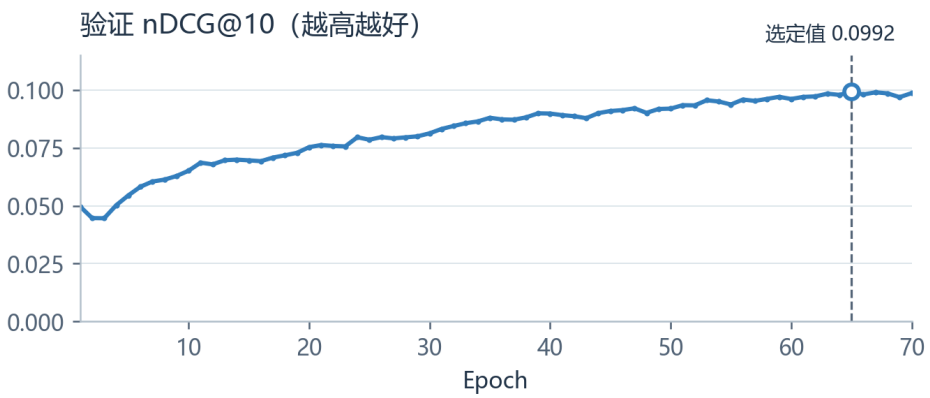
MF + Word2Vec L2：四项逐轮指标

选定 epoch 65 / 实际训练 70 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









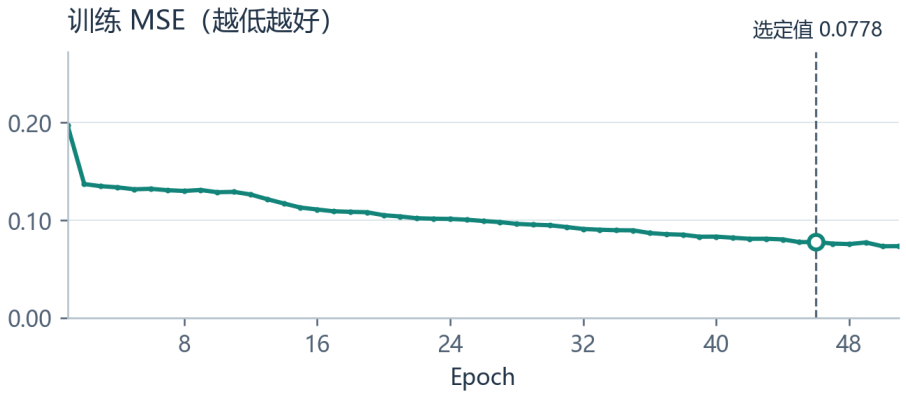
最终测试：Recall@10 = 0.1047 | HitRatio@10 = 0.3693 | nDCG@10 = 0.0917

第 65 轮的验证 nDCG 为 0.0992，选定训练 MSE 为 0.0630。记录截至第 70 轮；后续训练损失变化不改变已选 checkpoint。

曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

NCF + BERT 静态：四项逐轮指标

选定 epoch 46 / 实际训练 51 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









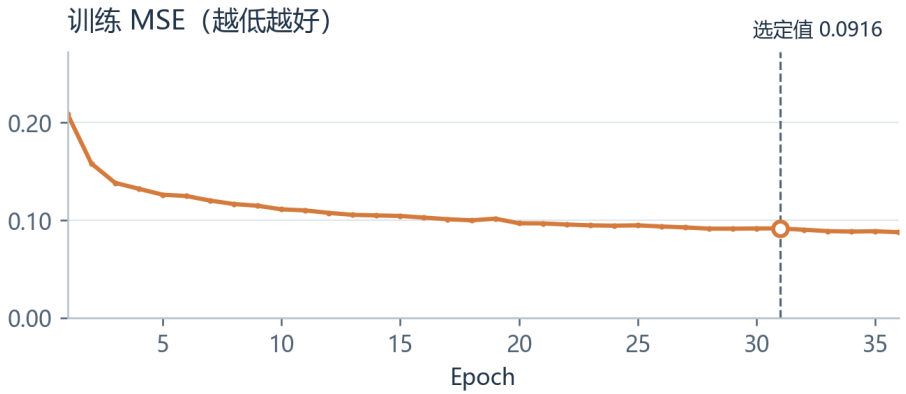
最终测试：Recall@10 = 0.1023 | HitRatio@10 = 0.3554 | nDCG@10 = 0.0914

第 46 轮的验证 nDCG 为 0.1016，选定训练 MSE 为 0.0778。记录截至第 51 轮；后续训练损失变化不改变已选 checkpoint。

曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

NCF + BERT 上下文：四项逐轮指标

选定 epoch 31 / 实际训练 36 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









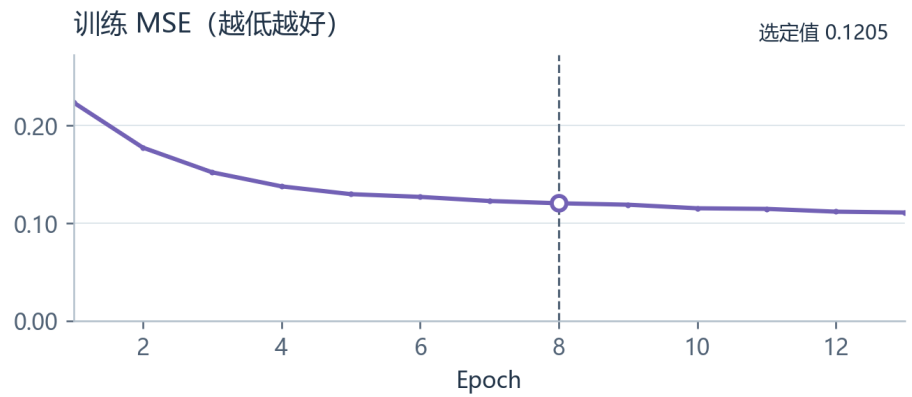
最终测试：Recall@10 = 0.1016 | HitRatio@10 = 0.3554 | nDCG@10 = 0.0926

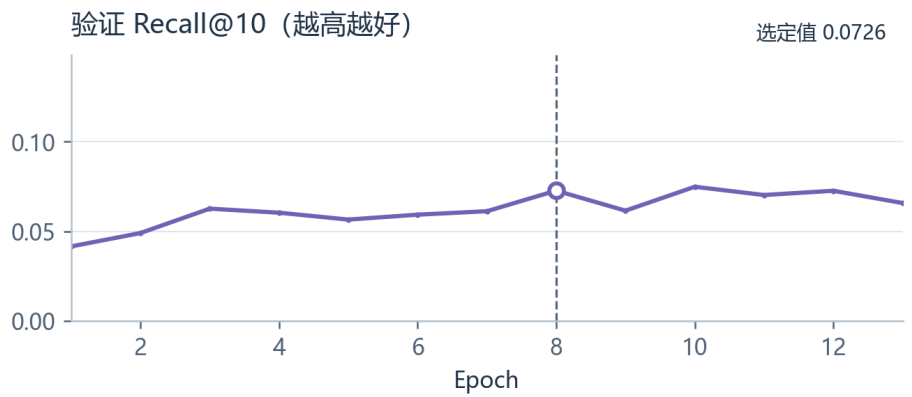
第 31 轮的验证 nDCG 为 0.1004，选定训练 MSE 为 0.0916。记录截至第 36 轮；后续训练损失变化不改变已选 checkpoint。

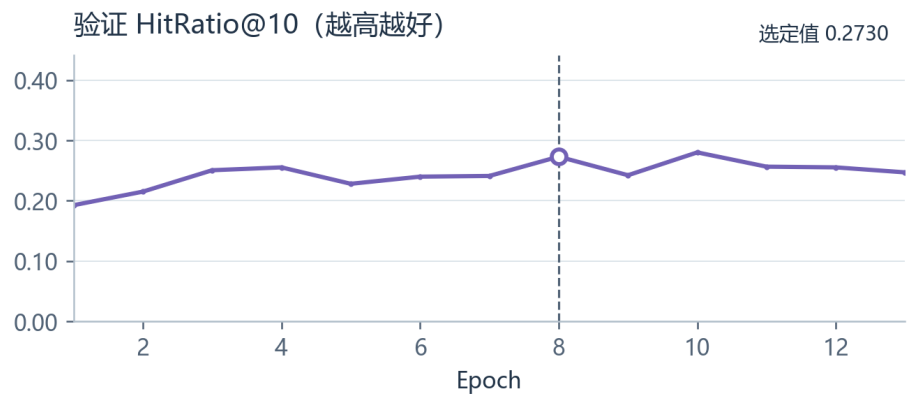
曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

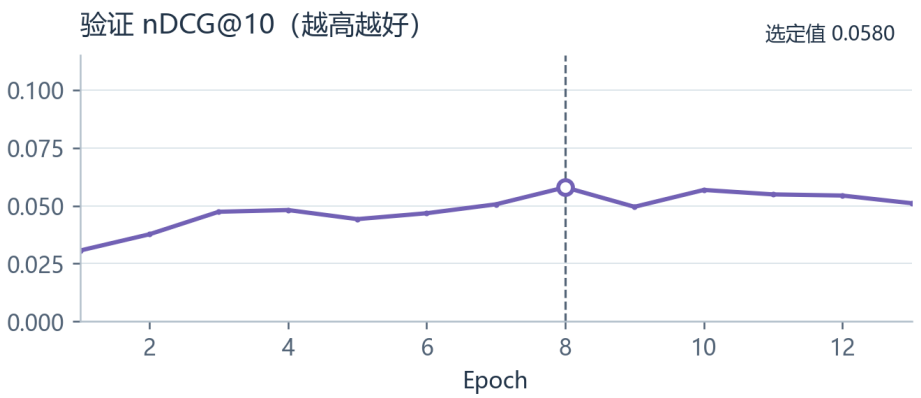
NCF + Word2Vec：四项逐轮指标

选定 epoch 8 / 实际训练 13 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









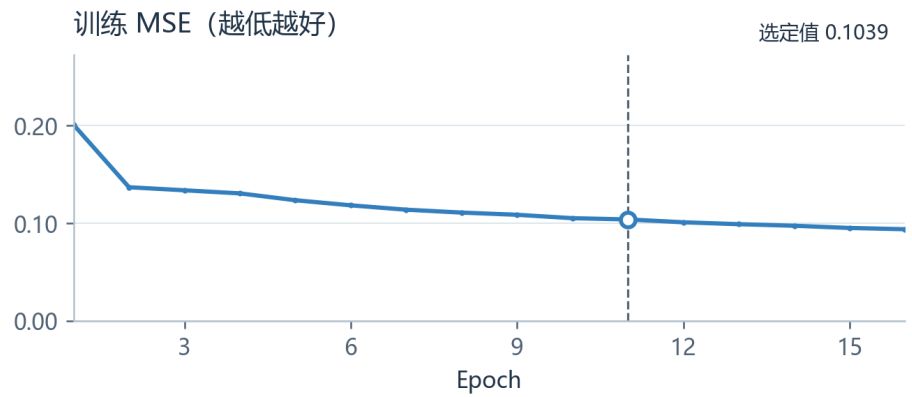
最终测试：Recall@10 = 0.0796 | HitRatio@10 = 0.3194 | nDCG@10 = 0.0702

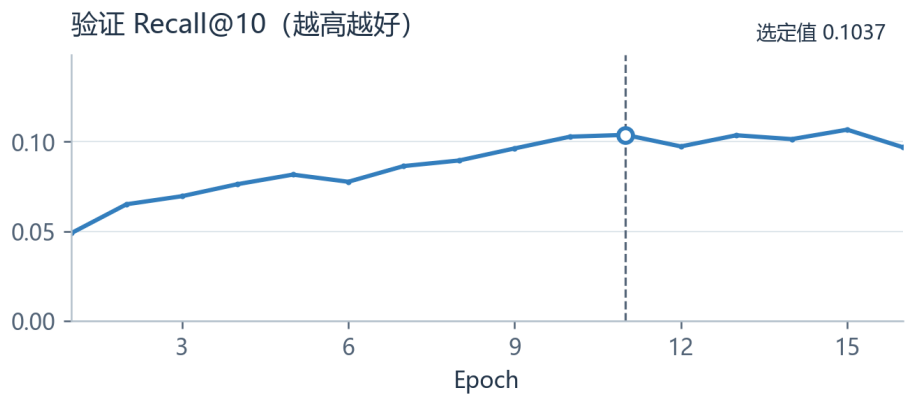
第 8 轮的验证 nDCG 为 0.0580，选定训练 MSE 为 0.1205。记录截至第 13 轮；后续训练损失变化不改变已选 checkpoint。

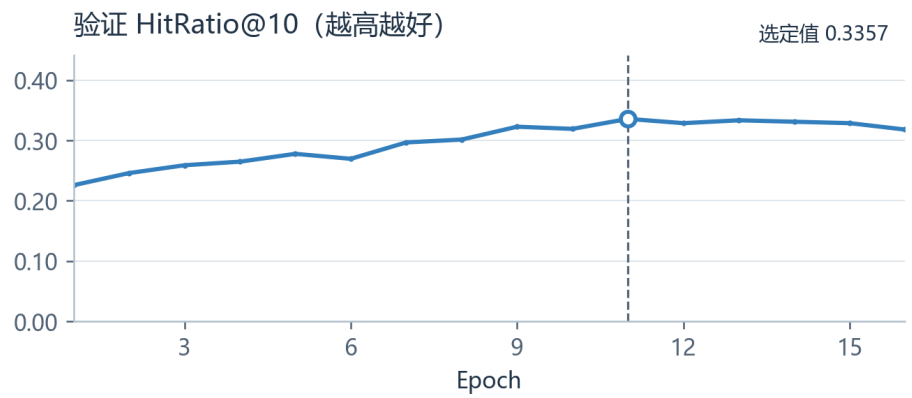
曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

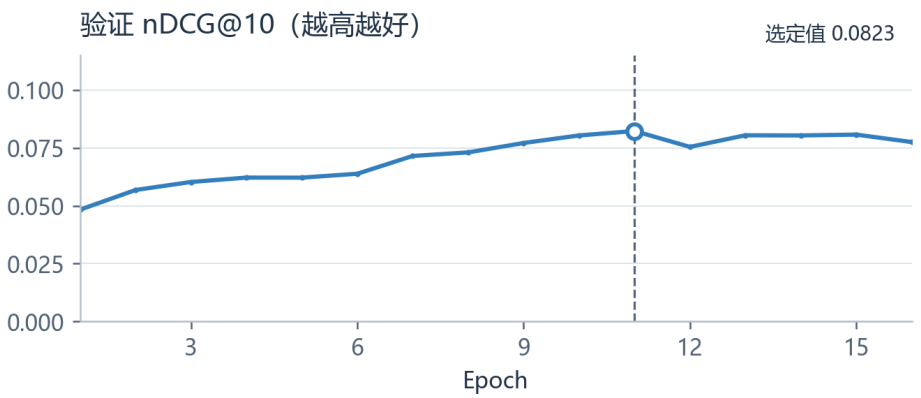
NCF + Word2Vec L2：四项逐轮指标

选定 epoch 11 / 实际训练 16 轮；虚线与空心圆标记同一个验证 nDCG 最优 checkpoint。









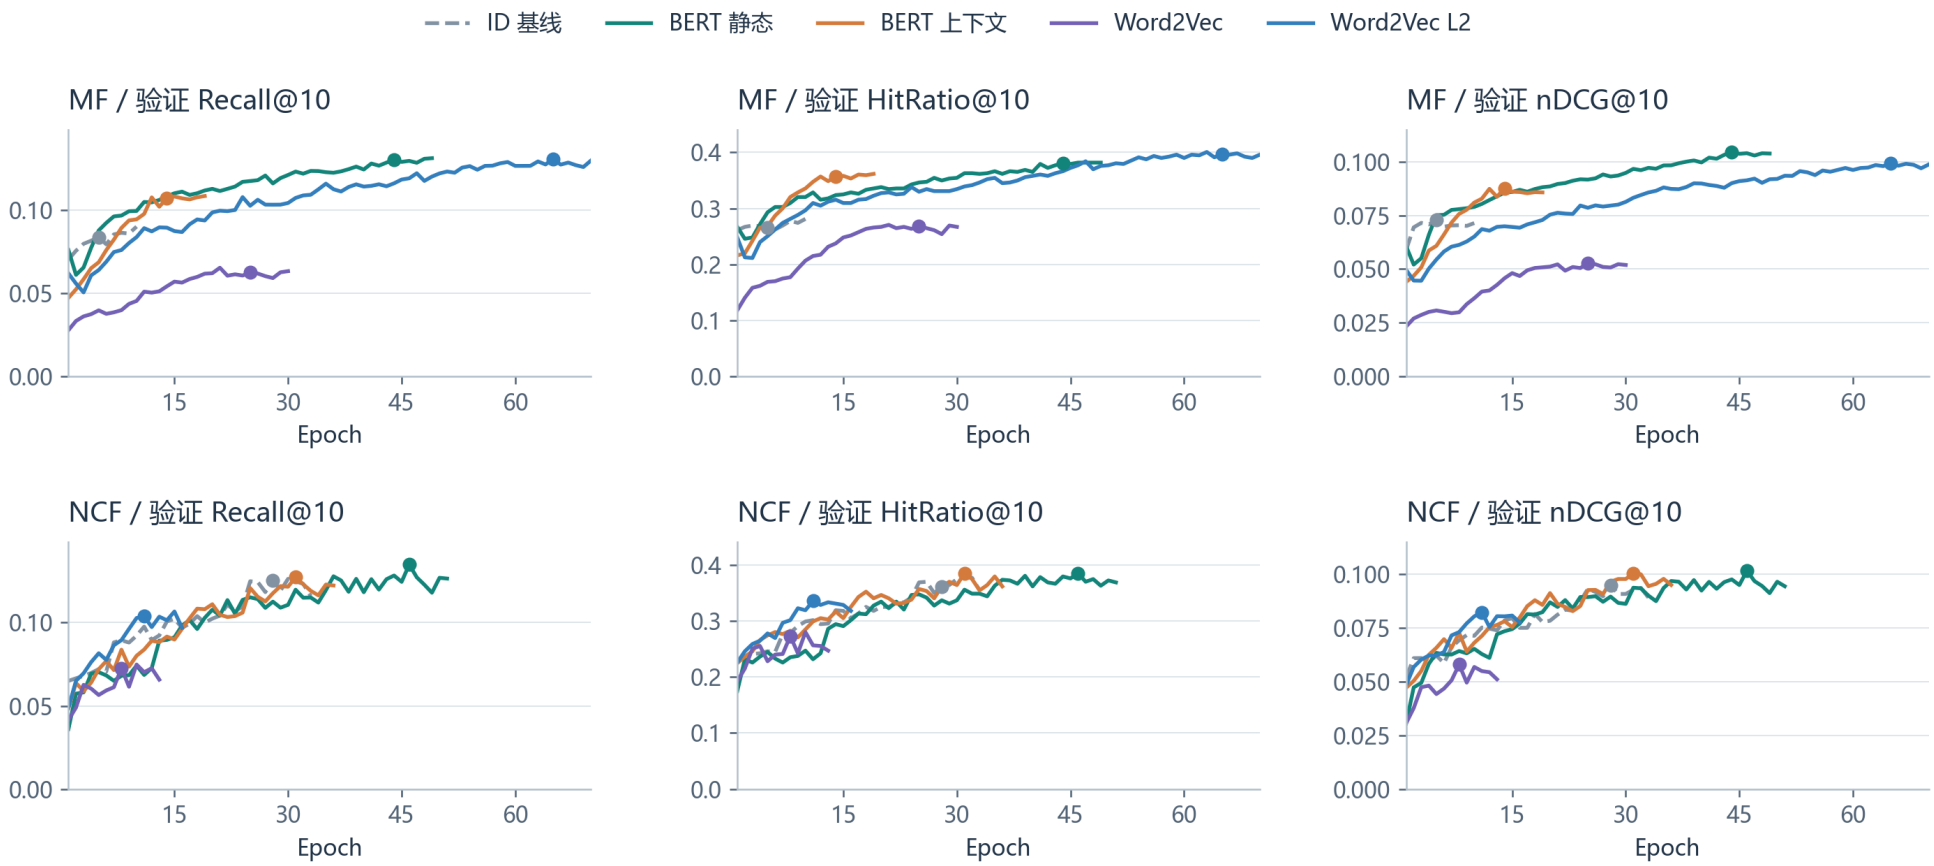
最终测试：Recall@10 = 0.0978 | HitRatio@10 = 0.3531 | nDCG@10 = 0.0842

第 11 轮的验证 nDCG 为 0.0823，选定训练 MSE 为 0.1039。记录截至第 16 轮；后续训练损失变化不改变已选 checkpoint。

曲线为逐轮原始值，不平滑、不延长结束后的序列。八组实验页面对同一指标使用相同纵轴量程。

验证曲线叠加：每个模型的五种表示

完整历史按实际训练轮数截断；圆点为各自选定 checkpoint，横轴统一到第 70 轮。



同一模型家族共享训练口径与评价人群，曲线展示真实波动。曲线长度表示训练轮数；日志未提供所有方法可比的耗时记录，因此不据此比较运行速度。

Word2Vec：归一化前后的直接对照

唯一输入改动为逐电影标题向量的 L2 归一化；两组均按验证 nDCG 提升纳入报告。

模型与标题表示	验证 nDCG@10	测试 Recall@10	测试 HitRatio@10	测试 nDCG@10
MF + Word2Vec	0.0528	0.0564	0.2532	0.0526
MF + Word2Vec L2	0.0992	0.1047	0.3693	0.0917
NCF + Word2Vec	0.0580	0.0796	0.3194	0.0702
NCF + Word2Vec L2	0.0823	0.0978	0.3531	0.0842

L2 版本	验证 nDCG 相对 原始 Word2Vec	测试 nDCG 相对 原始 Word2Vec	测试 nDCG 相对 ID 基线
MF	+88.05%	+74.20%	+10.42%
NCF	+41.97%	+20.02%	-2.87%

MF：L2 测试 nDCG 高于 ID 基线；相对变化 +10.42%。
NCF：L2 测试 nDCG 低于 ID 基线；相对变化 -2.87%。

处理位置：100 维电影标题均值向量 / max(L2 长度, 1e-12) → 可训练 100→64 投影 → 与电影 ID 相加。1,682 个非零向量长度由均值 26.5576 变为约 1；源向量文件保持原样。

原始与 L2 的参数初值、负采样及训练配置一致；按同一早停规则得到不同训练轮数。本页比较完整训练流程，单 seed 结果不构成统计显著性证据。

Word2Vec 的实际变化与方法选择

所有差值由保存的原始指标计算；以下结论仅适用于当前数据、配置和单次随机种子。

MF：按验证 nDCG 选择的方法为 BERT 静态（验证 0.1045，其测试 0.0976）。测试 nDCG 的最高观测值来自 BERT 静态（0.0976），该观察不作为选模型依据。

NCF：按验证 nDCG 选择的方法为 BERT 静态（验证 0.1016，其测试 0.0914）。测试 nDCG 的最高观测值来自 BERT 上下文（0.0926），该观察不作为选模型依据。

未归一化 Word2Vec 的历史对照：相对 ID 基线

模型	Δ Recall@10 百分点	Δ HitRatio@10 百分点	Δ nDCG@10 百分点	nDCG 相对变化
MF	-3.259	-8.711	-3.039	-36.61%
NCF	-2.016	-3.833	-1.654	-19.07%

MF Word2Vec 测试 nDCG：相对 BERT 静态 -4.495 个百分点；相对 BERT 上下文 -3.881 个百分点。
NCF Word2Vec 测试 nDCG：相对 BERT 静态 -2.117 个百分点；相对 BERT 上下文 -2.239 个百分点。

百分点表示分数之差乘以 100；相对变化表示比值变化。仅凭本次单 seed 的差异，不能断言某种词向量或编码方式普遍更优。

覆盖率、比较限制与可复现来源

完整保留 BERT、原始 Word2Vec 和 L2 Word2Vec；没有生成逐轮测试曲线。

解释结果时需要保留的边界

1. Word2Vec 元数据记录维度 100、词表 14,951；电影覆盖 1,682/1,682（100.00%），标题词命中 5,750/6,695（85.88%）。电影均有向量，不等于每个词均在词表内。外部预训练语料尚未核实；仅能确认本次推荐训练不读取验证/测试标签，不能据此断言整个预训练链路没有泄漏。
2. 所有结果只有一个 seed，未给出置信区间或显著性检验。原始与 L2 Word2Vec 初始可训练参数一致，各增加 6,400 个投影参数；BERT 增加 49,152 个。与 BERT/ID 的比较存在参数量、初值及预训练来源差异。
3. 评价仅覆盖训练期全局已知电影；测试排除了 13 条冷启动正反馈，不衡量冷启动收益。BERT 上下文编码使用项目内 PyTorch 实现，未新增与标准库的数值一致性验证。
4. L2 对照在观察历史实验后提出，按验证 nDCG 选 checkpoint 并判断纳入，未按本轮测试结果继续调参。原始与 L2 使用相同早停规则，训练轮数不同；稳健性需要多 seed 或独立数据确认。
5. 记录包含训练 MSE 与验证排序指标，不包含可比的验证损失、逐轮测试指标及全套运行时间。

原始记录与报告材料

ID 基线：outputs/ranking_benchmark_mixed_pool_100/
BERT 静态：outputs/bert_static_word_embedding_mixed_pool_100/
BERT 上下文：outputs/bert_contextual_title_mixed_pool_100/
Word2Vec：outputs/word2vec_title_mixed_pool_100/
Word2Vec L2：outputs/word2vec_title_l2_mixed_pool_100/

各目录内 mf_sampled_mse/metrics.json、ncf_sampled_mse/metrics.json 提供逐轮记录，summary.json 用于交叉核对。
Word2Vec 覆盖率：data/pretrained_word2vec/coverage.json；模型输入采用该目录提供的电影标题向量。
数据快照：results/bert_comparison_report_data.json，含八组与基线原始历史、配置、覆盖率、来源及图表 SHA-256。
生成脚本：build_bert_report.py（charts / pdf / verify）；图表：output/pdf/figures/（PNG 与 SVG）。